HELLENIC REPUBLIC
National and Kapodistrian
University of Athens
EST. 1837

RCT Assignment

Christos Athanasakopoulos

February 2026

Contents

1 Phase I (3+3) 3

1.1 Κώδικας . . . 3

1.1.1 Αποτελέσματα . . . 4

1.1.2 Σενάριο A . . . 4

1.1.3 Σενάριο B . . . 4

1.1.4 Σχολιασμός . . . 4

1.2 Early Probability Stopping . . . 5

1.3 Final Dose Recommendation (MTD) . . . 5

1.3.1 Κώδικας . . . 5

1.3.2 Αποτελέσματα . . . 6

1.4 Target Accuracy . . . 7

1.4.1 Graphical Interpretation . . . 8

1.4.2 Σύγκριση και Τελική Επιλογή . . . 9

1.5 Έλεγχος Συνέπειας . . . 9

2 Phase II, exact binomial και Simon two-stage 10

2.1 Single-Stage Exact Binomial Design . . . 10

2.1.1 Κώδικας . . . 10

2.1.2 Αποτελέσματα ανά Σενάριο . . . 11

2.2 Two-Stage Design . . . 12

2.2.1 Εύρεση Παραμέτρων (Κώδικας) . . . 12

2.2.2 Αποτελέσματα . . . 12

2.3 Σύγκριση Σχεδιασμών . . . 13

2.4 Decision . . . 14

2.5 Power under intermediate efficacy (p=0.30) . . . 14

2.5.1 Κώδικας . . . 15

2.5.2 Αποτελέσματα και Ερμηνεία . . . 16

2.6 Έλεγχος Συνέπειας . . . 16

3 Τυχαιοποίηση και Ανισορροπία 17

3.1 Θεωρητική Πιθανότητα . . . 17

3.2 Simulation . . . 17

3.3 Randomization List . . . 19

3.3.1 Λίστα . . . 19

3.3.2 Κώδικας . . . 20

3.4 Critical Appraisal . . . 20

3.5 Επιλογή Σχεδιασμού . . . 22

3.6 Έλεγχος Συνέπειας . . . 22

4 Interim Analysis, O'Brien-Fleming &Pocock **24**
4.0.1 Κώδικας 24
4.1 Boundaries 25
4.2 Σύγκριση Thresholds 25
4.3 Scenario Testing 26
4.4 Επιλογή (Selection) 26
4.5 Έλεγχος Συνέπειας 26

5 ΜΕΡΟΣ Β: Θεωρία **27**
5.1 Phase I Designs 27
5.2 Phase II Designs 28
5.3 Randomization &Bias 29
5.4 Interim Analysis 29
5.5 ITT vs Per Protocol 30

6 Συνολικός Κώδικας **31**

ΜΕΡΟΣ Α

1 Phase I (3+3)

Για τον υπολογισμό των πιθανοτήτων μετάβασης (Transition Probabilities) χρησιμοποιήσαμε τον αλγόριθμο του σχεδιασμού **3+3** σε περιβάλλον R. Ο κώδικας υπολογίζει αναλυτικά την πιθανότητα κλιμάκωσης (Escalation) βάσει του τύπου:

$$P_i = b(0; 3, p_i) + [b(1; 3, p_i) \times b(0; 3, p_i)]$$

Ο κώδικας που χρησιμοποιήθηκε είναι ο εξής:

1.1 Κώδικας

Listing 1: Συνάρτηση υπολογισμού πιθανοτήτων σε R

```
OC_3plus3 = function(p, doses=NULL){
  if (is.null(doses)) {
    doses = paste("Dose", seq_along(p))
  }
  #Probability of escalation (Pi)
  Pi = dbinom(0, size=3, prob=p) +
       dbinom(1, size=3, prob=p) * dbinom(0, size=3, prob
          =p)

  Qi = cumprod(Pi)
  OC = 1 - Qi

  data.frame(dose=doses, p=p, Pi=Pi, Qi=Qi, OC=OC)
}

#Run scenarios
res_ScenA = OC_3plus3(c(0.08, 0.18, 0.30, 0.45))
res_ScenB = OC_3plus3(c(0.12, 0.22, 0.28, 0.40))
```

1.1.1 Αποτελέσματα

Εφαρμόζοντας τη συνάρτηση στα σενάρια της άσκησης, προέκυψαν τα εξής αποτελέσματα για τις Transition Probabilities (στήλη P_i):

1.1.2 Σενάριο A

Οι πιθανότητες κλιμάκωσης στην επόμενη δόση φαίνονται στον Πίνακα 1.

Table 1: Operating Characteristics for Scenario A

Dose Level	Toxicity (p)	Escalation (P_i)	Reach (Q_i)	Stop (OC)
Dose 1	0.08	0.937	0.937	0.063
Dose 2	0.18	0.752	0.704	0.296
Dose 3	0.30	0.494	0.348	0.652
Dose 4	0.45	0.234	0.082	0.918

1.1.3 Σενάριο B

Οι πιθανότητες κλιμάκωσης για το δεύτερο σενάριο παρουσιάζονται στον Πίνακα 2.

Table 2: Operating Characteristics for Scenario B

Dose Level	Toxicity (p)	Escalation (P_i)	Reach (Q_i)	Stop (OC)
Dose 1	0.12	0.871	0.871	0.129
Dose 2	0.22	0.665	0.580	0.420
Dose 3	0.28	0.536	0.311	0.689
Dose 4	0.40	0.309	0.096	0.904

1.1.4 Σχολιασμός

Γενικά, παρατηρούμε ότι όσο αυξάνεται η πιθανότητα τοξικότητας, η πιθανότητα κλιμάκωσης μειώνεται δραματικά. Στο Σενάριο A, στη target dose (Dose 3, p=0.30), η πιθανότητα κλιμάκωσης στην επόμενη 4η δόση είναι **0.494**, κάτι το οποίο κρίνεται καλό έως και επιθυμητό για την ασφάλεια, περιορίζοντας έτσι την έκθεση στη πιο τοξική Δόση 4.

1.2 Early Probability Stopping

Με βάση τους Πίνακα 1 και 2 η πιθανότητα διακοπής πριν ενταχθούν οι ασθενείς στο 4ο επίπεδο δόσης (δηλαδή να σταματήσουμε στις Δόσεις 1, 2 ή 3) είναι:

- **Σενάριο A:** 65.2%
- **Σενάριο B:** 68.9%

Σχολιασμός: Και στα δύο σενάρια φαίνεται η πιθανότητα να σταματήσουμε νωρίς πριν τη 4η δόση να είναι αρκετά υψηλή ($> 65\%$). Αυτό ουσιαστικά επιβεβαιώνει το συντηρητικό χαρακτήρα της μεθόδου.

1.3 Final Dose Recommendation (MTD)

Για τον υπολογισμό της πιθανότητας κάθε δόσης ως MTD βασιστήκαμε στα αποτελέσματα της συνάρτησης `OC_3plus3` που χρησιμοποιήσαμε στο προηγούμενο ερώτημα.

Η πιθανότητα να προταθεί η δόση D_{i-1} ως MTD ισούται με την πιθανότητα η μελέτη να σταματήσει ακριβώς στη δόση D_i. Αυτό υπολογίζεται στο R ως η διαφορά των OC.

1.3.1 Κώδικας

Listing 2: Υπολογισμός κατανομής MTD βάσει των OC

```
#MTD Calc
#we want to calculate the difference OC[i]-OC[i-1]
#aka the probability of stopping the study exactly at
   dose i

#Scenario A
stop_probA= diff(c(0,res_ScenA$OC))
stop_probA
MTD_probs_A= c(
  None= stop_probA[1], #stop at dose 1 -> no MTD
  Dose1=stop_probA[2], #stop at dose 2 -> MTD Dose= 1
  Dose2=stop_probA[3], # stop at Dose 3 -> MTD Dose= 2
  Dose3= stop_probA[4], # stop at Dose 4 -> MTD Dose= 3
  Dose4= 1- res_ScenA$OC[4]#No stopping at all->MTD=Dose4
)
MTD_probs_A
```

```
# Scenario B
stop_probs_B = diff(c(0, res_ScenB$OC))
MTD_probs_B = c(
  None  = stop_probs_B[1],
  Dose1 = stop_probs_B[2],
  Dose2 = stop_probs_B[3],
  Dose3 = stop_probs_B[4],
  Dose4 = 1 - res_ScenB$OC[4]
)

#results
round(MTD_probs_A, 3)
round(MTD_probs_B, 3)
```

1.3.2 Αποτελέσματα

Τα αποτελέσματα του παραπάνω κώδικα φαίνονται στο παρακάτω Πίνακα 3 :

Table 3: Probability of MTD Selection for Scenarios A and B

MTD Selection	Scenario A (Prob)	Scenario B (Prob)
None (Unsafe)	0.063	0.129
Dose 1	0.233	0.292
Dose 2	0.356	0.269
Dose 3	0.266	0.214
Dose 4	0.082	0.096

Σχολιασμός: Στο Σενάριο A, η δόση με τη μεγαλύτερη πιθανότητα επιλογής είναι η **Dose 2** (35.6%). Στο Σενάριο B, λόγω της υψηλότερης τοξικότητας στις αρχικές δόσεις, αυξάνεται σημαντικά η πιθανότητα να μην επιλεγεί καμία δόση (12.9%) ή να επιλεγεί η χαμηλότερη Dose 1 (29.2%).

1.4 Target Accuracy

Ως target dose ορίζουμε τη δόση με πιθανότητα τοξικότητας περίπου $p \approx 0.30$.

- Στο **Σενάριο A**, η Dose 3 έχει $p = 0.30$ και αποτελεί την πραγματική MTD.
- Στο **Σενάριο B**, η πιο κοντινή στο 0.30 είναι επίσης η Dose 3 ($p = 0.28$).

Επομένως, για την αξιολόγηση της Target Accuracy εξετάζουμε την πιθανότητα επιλογής της **Dose 3** ως τελική επιλογή.

Από τον Πίνακα 3 προκύπτει ότι:

- **Σενάριο A:** $P(\text{Select Dose 3}) = 26.6\%$
- **Σενάριο B:** $P(\text{Select Dose 3}) = 21.4\%$

Σχολιασμός: Το 3+3 design επιτυγχάνει καλύτερα το στόχο της σωστής MTD στο Σενάριο A σε σχέση με το Σενάριο B.

Στο Σενάριο B παρατηρείται αυξημένη πιθανότητα επιλογής χαμηλότερων δόσεων (Dose 1 ή Dose 2), γεγονός που υποδηλώνει τάση υποεκτίμησης της MTD. Αυτό σχετίζεται με την πιο συντηρητική φύση του 3+3 αλγορίθμου που έχει τη τάση να υποεκτιμά την MTD.

Συνεπώς, ως προς την Target Accuracy, το Σενάριο A εμφανίζει καλύτερη απόδοση του σχεδιασμού 3+3.

1.4.1 Graphical Interpretation

Για την οπτική επιβεβαίωση των παραπάνω αποτελεσμάτων, παρουσιάζονται τα διαγράμματα της καμπύλης τοξικότητας και OC.

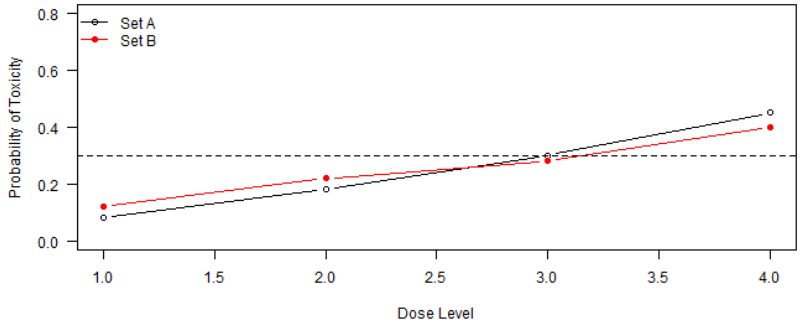

Figure 1: Dose–toxicity relationship για τα δύο σενάρια. Η διακεκομμένη γραμμή υποδηλώνει το target επίπεδο $p = 0.30$.

Στο Σενάριο A παρατηρείται μια πιο απότομη αύξηση της τοξικότητας μετά την Dose 3, γεγονός που δημιουργεί ευδιάκριτο διαχωρισμό μεταξύ της target dose και των πιο τοξικών δόσεων. Αντίθετα, στο Σενάριο B η αύξηση είναι πιο ομαλή, καθιστώντας δυσκολότερη τη διάκριση της βέλτιστης δόσης από τις πλησιέστερες σε αυτή δόσεις.

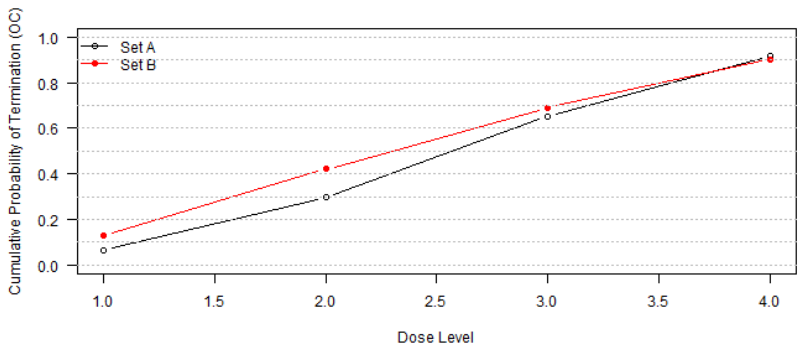

Figure 2: Cumulative Probability of Termination (OC) για τα δύο σενάρια.

Από το Γράφημα 2 παρατηρούμε ότι η καμπύλη OC δείχνει ότι στο Σενάριο B η πιθανότητα πρόωρης διακοπής αυξάνεται ταχύτερα (ενώ είναι πάντα και

υψηλότερη από αυτή του A), γεγονός που οδηγεί σε μεγαλύτερη πιθανότητα επιλογής χαμηλότερων δόσεων και μειωμένη πιθανότητα επιλογής της target dose.

Τα γραφήματα συνεπώς επιβεβαιώνουν το αριθμητικό συμπέρασμα ότι το Σενάριο A παρουσιάζει καλύτερη Target Accuracy.

1.4.2 Σύγκριση και Τελική Επιλογή

Με βάση όλη τη προηγούμενη ανάλυση αν έπρεπε να επιλέξουμε ένα σενάριο αυτό θα ήταν το **Σενάριο A**.

Το Σενάριο A όπως είδαμε έχει Target Accuracy υψηλότερη σε σχέση με το Σενάριο B (26,6% vs 21,4%). Αυτό δείχνει ότι εντοπίζει πιο εύκολα τη πραγματική MTD.

Από την άλλη πλευρά, το Σενάριο B είναι αυτό στο οποίο γίνεται πιο αισθητή η αδυναμία του σχεδιασμού όπως αναφέραμε και παραπάνω. Όπως φάνηκε, λόγω της μεγαλύτερης τοξικότητας στις αρχικές δόσεις, ο αλγόριθμος συμπεριφέρεται υπερβολικά συντηρητικά. Αυτό οδηγεί σε πρόωρο τερματισμό της μελέτης σε δόσεις σημαντικά χαμηλότερες (Dose 1 ή 2) από τη βέλτιστη, οδηγώντας με αυτό το τρόπο σε "υπό-θεραπεία".

Επομένως, το Σενάριο A κρίνεται βέλτιστο μεταξύ των δύο αφού ο σχεδιασμός φαίνεται να αποδίδει καλύτερα και να κρατάει καλύτερη ισορροπία μεταξύ αποτελεσματικότητας και ασφάλειας.

1.5 Έλεγχος Συνέπειας

Αν αυξάναμε όλες τις πιθανότητες τοξικότητας (p) κατά +0.05, η αλλαγή θα γινόταν πρώτα αντιληπτή στην πιθανότητα κλιμάκωσης P_i.

Ο αλγόριθμος υπολογίζει πρώτα τη πιθανότητα κλιμάκωσης από τη μία δόση στην επόμενη (P_i), χρησιμοποιώντας τη πιθανότητα τοξικότητας p, μέσω της Διωνυμικής Κατανομής. Όλα τα υπόλοιπα μεγέθη υπολογίζονται με βάση αυτά τα P_i. Συνεπώς, αν αυξήσουμε έστω και κατά 0.05 τη πιθανότητα τοξικότητας αυτό θα οδηγούσε αμέσως σε μείωση της πιθανότητας κλιμάκωσης (P_i), η οποία με τη σειρά της θα αύξανε τη πιθανότητα πρόωρου τερματισμού.

2 Phase II, exact binomial και Simon two-stage

2.1 Single-Stage Exact Binomial Design

Στο πρώτο μέρος της συγκεκριμένης άσκησης αναζητούμε το μέγεθος δείγματος n και το κριτικό όριο r του αριθμού των ανταποκρίσεων για έναν exact binomial σχεδιασμό (χωρίς ενδιάμεση ανάλυση).

Ο αλγόριθμος στηρίζεται στην Exact Binomial κατανομή, αυξάνει το n σταδιακά μέχρι να βρεθεί το μικρότερο n για το οποίο υπάρχει ένα r που ικανοποιεί ταυτόχρονα τα παρακάτω:

$$P(X > r|p_0) \leq \alpha \quad \text{και} \quad P(X > r|p_1) \geq 1 - \beta$$

2.1.1 Κώδικας

Στο παρακάτω κώδικα R, η μεταβλητή `k_crit` αντιστοιχεί στο κριτικό όριο r.

Listing 3: Single-Stage Design function

```
single_stage= function(p0,p1,alpha,power) {
 n=1
 while(TRUE) {
   #find the smallest k : P(X>k|p0)<=alpha
   kvec=0:n
   ptail0= pbinom(kvec,size = n, prob = p0, lower.tail =
       F)
   idx= which(ptail0<=alpha)[1]

   if (!is.na(idx)) {
     k_crit=kvec[idx] #if X>k_crit we reject H0
     #we calculate the power P(X>k_crit|p1)
     ptail1= pbinom(k_crit,size = n,prob = p1,lower.tail
         = F)

     if (ptail1>=power) {
       return(c(n=n,k=k_crit,alpha_exact=ptail0[idx],
           power_exact=ptail1))
     }
   }
   n=n+1
 }
}
```

2.1.2 Αποτελέσματα ανά Σενάριο

Εφαρμόσαμε το παραπάνω αλγόριθμο στα δύο παρακάτω σενάρια:

- **Σενάριο A:** $p_0 = 0.15, p_1 = 0.40, \alpha = 0.10, power = 0.80$
- **Σενάριο B:** $p_0 = 0.20, p_1 = 0.40, \alpha = 0.05, power = 0.9\sigma 0$

Καλώντας, λοιπόν, τη παραπάνω συνάρτηση για τα δύο παραπάνω σενάρια πήραμε τα παρακάτω αποτελέσματα όπως φαίνονται στο Πίνακα 4 :

Listing 4: Call Single-Stage Design

```
res_single_A <-single_stage(0.15, 0.40, 0.10, 0.80)
round(res_single_A,3)
res_single_B <- single_stage(0.20, 0.40, 0.05, 0.90)
round(res_single_B,3)
```

Table 4: Αποτελέσματα Μονοσταδιακού Σχεδιασμού

Scenario	n	r (Cutoff)	α (Exact)	Power (Exact)
A	16	4	0.079	0.833
B	47	14	0.037	0.901

Ερμηνεία

Όπως φάνηκε από το παραπάνω Πίνακα 4 έχουμε:

- **Σενάριο A:** Ο σχεδιασμός απαιτεί συνολικό δείγμα 16 ασθενών και κριτικό όριο το $r = 4$. Αυτό σημαίνει ότι αν παρατηρηθούν ≤ 4 αποκρίσεις δε μπορούμε να απορρίψουμε τη μηδενική υπόθεση και άρα το φάρμακο θεωρείται αναποτελεσματικό. Αντίθετα, αν δούμε ≥ 5 αποκρίσεις η μηδενική υπόθεση απορρίπτεται και άρα το φάρμακο θεωρείτο επαρκώς αποτελεσματικό. Το πραγματικό σφάλμα τύπου I είναι 0.079 που είναι μικρότερο από το ζητούμενο 0.1 και η ισχύς 0.833 (≥ 0.80) ικανοποιώντας έτσι τις απαιτήσεις του σχεδιασμού.
- **Σενάριο B:** Ο σχεδιασμός απαιτεί ένα σύνολο 47 ασθενών με κριτικό όριο $r = 14$ παρουσιάζοντας έτσι μια δραματική αύξηση στο μέγεθος δείγματος. Το πραγματικό σφάλμα τύπου I είναι 0.037 και η ισχύς 0.901 ικανοποιώντας και εδώ τους περιορισμούς.

2.2 Two-Stage Design

Σε αυτό το σημείο θα προχωρήσουμε εφαρμόζοντας για κάθε ένα από τα παραπάνω Σενάρια Simon Two-Stage Design.

2.2.1 Εύρεση Παραμέτρων (Κώδικας)

Ξεκινάμε με την εύρεση των παραμέτρων για Optimal & Minimax σχεδιασμό. Για αυτό το σκοπό χρησιμοποιήσαμε από την library `clinfun` της R τη συνάρτηση `ph2simon`.

Ο κώδικας δίνεται παρακάτω:

Listing 5: Simon Two-Stage

```
### Two Stage Design ###
library(clinfun)
#Scenario A
simon_A= ph2simon(pu=0.15,pa=0.40,ep1 = 0.10,ep2 = 0.20,
   nmax = 100)
#Scenario B
simon_B=ph2simon(pu=0.20,pa=0.40,ep1 = 0.05,ep2 = 0.10,
   nmax = 100)
#Results
simon_A
simon_B
```

2.2.2 Αποτελέσματα

Στον παρακάτω Πίνακα 5 δίνονται συγκεντρωτικά οι παράμετροι για τους σχεδιασμούς Optimal και Minimax και για τα δύο σενάρια.

Table 5: Παράμετροι Σχεδιασμών Simon (Optimal & Minimax)

Scenario	Design	r_1	n_1	r	n_{max}	$EN(p_0)$	$PET(p_0)$
A	Minimax	1	9	4	16	11.80	0.600
	Optimal	1	7	4	18	10.12	0.717
B	Minimax	5	24	13	45	31.23	0.656
	Optimal	4	19	15	54	30.43	0.673

Σημείωση: Για το Σενάριο A ($p_0 = 0.15, p_1 = 0.40$) και το Σενάριο B ($p_0 = 0.20, p_1 = 0.40$). Τα $EN(p_0)$ και $PET(p_0)$ αναφέρονται στον αναμενόμενο αριθμό ασθενών και την πιθανότητα πρόωρης διακοπής υπό τη μηδενική υπόθεση.

2.3 Σύγκριση Σχεδιασμών

Σε αυτό το σημείο θα συγκρίνουμε τους τρεις τύπους σχεδιασμών (Single Stage, Simon Optimal, Simon Minimax) για κάθε ένα απ'τα δύο σενάρια, εστιάζοντας στο μέγιστο μέγεθος δείγματος n, το αναμενόμενο μέγεθος δείγματος υπό τη μηδενική υπόθεση ($EN(p_0)$) και τη πιθανότητα πρώιμου τερματισμού $PET(p_0)$

Στον Πίνακα 6 συγκρίνονται οι τρεις προσεγγίσεις:

Table 6: Συγκριτικός Πίνακας Σχεδιασμών (Single vs Two-Stage)

Scenario	Design	N_{max}	$EN(p_0)$	$PET(p_0)$
	Single-Stage	16	16.00	0.00
A	Simon Minimax	16	11.80	0.60
	Simon Optimal	18	10.12	0.72
	Single-Stage	47	47.00	0.00
B	Simon Minimax	45	31.23	0.66
	Simon Optimal	54	30.43	0.67

Σχολιασμός

- Ο **Single-Stage** είναι αρκετά πιο απόλυτος και λιγότερα ηθικά σωστός. Ο αναμενόμενος αριθμός ασθενών που εκτίθενται υπό τη μηδενική υπόθεση δηλαδή σε περίπτωση που το φάρμακο είναι αναποτελεσματικό είναι το σύνολο των ασθενών (16 ή 47 αντίστοιχα στα δύο σενάρια).

- Ο **Simon Optimal** ελαχιστοποιεί τον αναμενόμενο αριθμό ασθενών αν ισχύει η H_0.Στο **Σενάριο A** γλυτώνει κατά μέσο όρο περίπου 6 ασθενείς σε σχέση με τον Single-Stage.

- Ο **Simon Minimax** ελαχιστοποιεί τον **μέγιστο** αριθμό ασθενών (n) στο χειρότερο σενάριο. Στο **Σενάριο B**, απαιτεί σημαντικά λιγότερους ασθενείς σε σχέση με τον Optimal στο τέλος της μελέτης (45 vs 54) με ένα πολύ μικρό κόστος στον αναμενόμενο αριθμό ασθενών που εκθέτουμε (31.2 vs 30.4).

2.4 Decision

Με βάση όλα τα παραπάνω, οι προτάσεις για τον κλινικό ιατρό ανάλογα με το σενάριο διαμορφώνονται ως εξής:

Καταρχάς, θεωρούμε ότι ο Single-Stage σχεδιασμός είναι εκτός κάδρου για ηθικούς λόγους μιας και εκθέτει όλους τους ασθενείς χωρίς κανένα μέτρο ασφαλείας. Από 'κει και πέρα έχουμε:

Σενάριο A ($p_0 = 0.15, p_1 = 0.40$)

Στο Σενάριο A θα προτιμούσαμε τον **Simon Optimal** σχεδιασμό. Η διαφορά στο μέγιστο αριθμό ασθενών μεταξύ των δύο σχεδιασμών είναι πάρα πολύ μικρή, ενώ το όφελος στη πιθανότητα πρώιμης διακοπής σε περίπτωση που το φάρμακο είναι αναποτελεσματικό είναι αρκετά μεγαλύτερο (73% vs 60%). Με αυτό το τρόπο επιλέγουμε να προστατεύσουμε τους ασθενείς από μια ενδεχόμενη αναποτελεσματική θεραπεία ελαχιστοποιώντας τον αναμενόμενο αριθμό ασθενών υπό τη μηδενική υπόθεση. Πρακτικά, ελαχιστοποιούμε την έκθεση σε μη δραστικό φάρμακο.

Σενάριο B ($p_0 = 0.20, p_1 = 0.40$)

Στο Σενάριο B παρατηρούμε ότι οι πιθανότητες πρώιμου τερματισμού είναι πάρα πολύ κοντά για τους δύο σχεδιασμούς, όπως και ο αναμενόμενος αριθμός εκτεθέντων ασθενών. Σημαντική διαφορά παρατηρείται στον μέγιστο αριθμό εκτεθέντων. Ο Optimal θα απαιτούσε 9 επιπλέον ασθενείς για να ολοκληρωθεί η μελέτη. Σε αυτή τη περίπτωση, για οικονομία πόρων, ταχύτητα ολοκλήρωσης (αν το φάρμακο δουλεύει) αλλά και κυρίως εκτεθέντων ασθενών θα επιλέγαμε τον **Minimax** σχεδιασμό.

2.5 Power under intermediate efficacy (p=0.30)

Σε αυτό το σημείο της ανάλυσης, εξετάσαμε τη συμπεριφορά των επιλεγμένων σχεδιασμών σε μία ενδιάμεση-μέτρια τιμή αποτελεσματικότητας, $p = 0.3$.Για τον υπολογισμό της ισχύος χρησιμοποιήθηκε ξανά ο τύπος Διωνυμικής Κατανομής, λαμβάνοντας υπόψη τη δεσμευμένη πιθανότητα μετάβασης στο 2ο στάδιο. Ο Κώδικας δίνεται παρακάτω:

2.5.1 Κώδικας

Listing 6: Υπολογισμός Ισχύος Simon για $p = 0.30$

```
##find power if p=0.3
p_true=0.3
# Scenario A
# Parameters: n1=7, r1=1, Total_N=18, Total_r=4
# Stop if Stage 1 responses (x1) <= 1. Continue if x1 > 1
# We sum the probabilities only for cases
# where the trial continues (x1 from 2 to 7).
n1=7
r1=1
N=18
r=4
n2=N-n1
x1_val= (r1+1):n1
power_A=sum(dbinom(x1_val,n1,p_true)
 # probability of getting enough responses
 # in stage 2 to reach total r>4
            *pbinom(r-x1_val,n2,p_true,lower.tail =F ))
            #we need x2< (4-x1) from the remaining 18-7
               patients
round(power_A,3)
#Scenario B
# Parameters: n1=24, r1=5, Total_N=45, Total_r=13
# We stop if Stage 1 responses (x1) <= 5. Continue if x1
   > 5
# The loop runs for x1 = 6 to 24
n1 = 24
r1 = 5
N  = 45
r  = 13
n2 = N - n1
x1_val= (r1+1):n1
power_B <- sum(
  # Probability of observing x1 responses in
  # Stage 1 (x1 must be > 5 to continue)
  dbinom(x1_val, n1,p_true) * # Probability of success in
      Stage 2 given x1
    # We need total responses > 13, so x2 > (13 - x1)
    pbinom(r-x1_val, n2, p_true, lower.tail=F)
)
round(power_B,3)
```

2.5.2 Αποτελέσματα και Ερμηνεία

Τα αποτελέσματα της ανάλυσης ισχύος για $p = 0.30$ είναι τα εξής:

- **Σενάριο A (Optimal):** Ισχύς = **0.544**
- **Σενάριο B (Minimax):** Ισχύς = **0.468**

Σχολιασμός:

1. **Intermediate Operating Characteristics:** Και οι δύο σχεδιασμοί παρουσιάζουν ισχύ κοντά στο 50% . Αυτό είναι αναμενόμενο στους σχεδιασμούς δύο σταδίων, οι οποίοι δουλεύουν καλύτερα σε περιοχές κοντά στην H_0 και H_1 έχοντας μία binary λογική (Go/No Go) ξεχωρίζοντας το p_0 από το p_1, ενώ η καμπύλη αλλάζει απότομα σε ενδιάμεσες περιοχές μεταξύ των δύο υποθέσεων ($p_0 < p < p_1$). Αυτό έχει σαν αποτέλεσμα μία μέτρια θεραπεία να κινδυνεύει να απορριφθεί σαν αναποτελεσματική.

2. **Σύγκριση Σεναρίων:** Παρατηρούμε ότι το Σενάριο B έχει χαμηλότερη ισχύ (0.468) σε σχέση με το Σενάριο A (0.544). Αυτό οφείλεται στο γεγονός ότι το Σενάριο B σχεδιάστηκε με αυστηρότερο σφάλμα τύπου I ($\alpha = 0.05$) έναντι του A ($\alpha = 0.10$).Ωστόσο, μία πιο αυστηρή προσέγγιση ενέχει το κόστος να γίνει ο σχεδιασμός λιγότερο αξιόπιστος και άρα να απορρίπτει πιο εύκολα θεραπείες που δεν είναι ξεκάθαρα ανώτερες.

2.6 Έλεγχος Συνέπειας

Σε περίπτωση που μπερδεύαμε one-sided με two-sided α θα μπορούσαμε πολύ εύκολα να το να παρατηρήσουμε αυτό το λάθος στο μέγεθος δείγματος N.

Στις κλινικές δοκιμές Φάσης II, ο έλεγχος υποθέσεων είναι τυπικά **μονόπλευρος (one-sided)**, καθώς ελέγχουμε αν η αποτελεσματικότητα p είναι μεγαλύτερη από ένα ιστορικό ποσοστό p_0 ($H_1 : p > p_0$). Δεν μας ενδιαφέρει η περίπτωση που το φάρμακο είναι χειρότερο (αρνητική ουρά), καθώς και στις δύο περιπτώσεις (ίσο ή χειρότερο) η ανάπτυξη του φαρμάκου διακόπτεται.

Αν ορίσουμε λανθασμένα το επίπεδο σημαντικότητας $\alpha = 0.05$ ως **δίπλευρο (two-sided)**, αυτό ισοδυναμεί πρακτικά με αμφίπλευρο έλεγχο σε $\alpha/2 = 0.025$ σε κάθε ουρά. Επειδή το κριτήριο 0.025 είναι πολύ αυστηρότερο από το ζητούμενο 0.05, ο αλγόριθμος (είτε Exact Binomial είτε Simon) θα απαιτούσε **σημαντικά μεγαλύτερο αριθμό ασθενών** για να διατηρήσει την ίδια ισχύ (Power).

3 Τυχαιοποίηση και Ανισορροπία

Στην άσκηση αυτή εξετάζουμε μια κλινική δοκιμή με $N = 80$ ασθενείς σε δύο ομάδες A και B αναλογίας 1:1 κάτω από δύο διαφορετικά Σενάρια.

- **Σενάριο A:** Simple Randomization
- **Σενάριο B:** Permuted Block Randomization με block size = 4

3.1 Θεωρητική Πιθανότητα

Στο Σενάριο A (Απλή Τυχαιοποίηση), ο αριθμός των ασθενών στην ομάδα A ακολουθεί τη Διωνυμική Κατανομή δηλαδή $N_A \sim B(80, \frac{1}{2})$. Η πιθανότητα να έχουμε τέλεια ισορροπία (δηλαδή $N_A = 40$ & $N_B = 40$) υπολογίστηκε στην `R` ως:

$$P(X = 40) = \binom{80}{40}(\frac{1}{2})^{80} \approx 0.0889$$

Δηλαδή, υπάρχει πιθανότητα μόλις **8,89 %** να καταλήξουν οι δύο ομάδες να είναι ίδιες εντελώς τυχαία. Αυτό επιβεβαιώνει ότι η απλή τυχαιοποίηση δε πετυχαίνει ακριβή ισορροπία σε μικρά δείγματα.

Ο Κώδικας που χρησιμοποιήθηκε φαίνεται παρακάτω:

Κώδικας

Listing 7: Simple Randomization

```
### Askisi 3 ####
set.seed(123) #for reproducibility
N=80
prob_exact=dbinom(x=N/2,size = N,p=0.5)
round(prob_exact,4)
```

3.2 Simulation

Σε αυτό το υποερώτημα θα προσομοιώσουμε 1000 επαναλήψεις simple randomization και θα υπολογίσουμε το εμπειρικό 95 % C.I. της αναλογίας των ασθενών που κατέληξαν στην ομάδα A.

Αποτελέσματα

Από τη προσομοίωση προέκυψε ότι το 95 % C.I. της αναλογίας των ασθενών στην ομάδα A κυμάνθηκε μεταξύ:

$$95\% \text{ CI} : [0.40, 0.6125]$$

Αυτό σημαίνει ότι σε κάποιες δοκιμές η αναλογία έπεσε στο 40 % (32 ασθενείς) ή ανέβηκε στο 61,25 % (49 ασθενείς). Μια τέτοια ανισορροπία μπορεί να μειώσει την ισχύ της μελέτης και να εισάγει bias.

Ο κώδικας που χρησιμοποιήθηκε φαίνεται παρακάτω:

Κώδικας

Listing 8: MC Simulation

```
# Simulation
#Simulation Parameters
set.seed(123)
N=80
K=1000

results= data.frame(
  replication = 1:K,
  NumberA= NA_integer_
)

#loop
for (i in 1:K) {
  u= runif(N)
  #We directly calculate the number in Arm A.
  results$NumberA[i]=sum(u<0.5)
}
ci_95= quantile(results$NumberA/N, probs = c(0.025,0.975)
   )
round(ci_95,4)
```

3.3 Randomization List

Χρησιμοποιώντας τη συνάρτηση `blockrand` της ομώνυμης `library` της `R` με μέγεθος block = 4, δημιουργήθηκε λίστα τυχαιοποίησης για το **Σενάριο B**.

3.3.1 Λίστα

Η ζητούμενη λίστα φαίνεται στο παρακάτω Πίνακα 7

Table 7: Λίστα Τυχαιοποίησης (Πρώτοι 20 Ασθενείς) - Block Size 4

Subject ID	Block ID	Treatment
1	1	A
2	1	A
3	1	B
4	1	B
5	2	A
6	2	B
7	2	A
8	2	B
9	3	A
10	3	A
11	3	B
12	3	B
13	4	A
14	4	B
15	4	B
16	4	A
17	5	B
18	5	B
19	5	A
20	5	A

3.3.2 Κώδικας

Ο κώδικας που χρησιμοποιήθηκε φαίνεται παρακάτω:

Listing 9: Block Randomization-Block Size=4

```
#Scenario B Block Randomization
#Block size=4
library(blockrand)
set.seed(123)
block_rand=blockrand(
  n=N,
  num.levels = 2,
  levels = c("A","B"),
  block.sizes = 2 # num.levels*block.sizes=4
)
first_20 =head(block_rand,20)
# Check Balance
table(block_rand$treatment)
```

Όπως φαινεται και από το παραπάνω κώδικα κάναμε και έναν έλεγχο ισορροπίας όπου μας επιβεβαίωσε ότι σε κάθε block είχαμε 40 ασθενείς.

3.4 Critical Appraisal

Σε αυτό το σημείο θα συγκρίνουμε τα δύο σενάρια (Simple vs Block Randomization) ως προς τους δύο παρακάτω άξονες:

- Τον κίνδυνο ανισορροπίας, και
- Την προβλεψιμότητα

Κίνδυνος Ανισορροπίας (Imbalance Risk)

- **Σενάριο A (Simple Randomization)**
  - **Ο κίνδυνος είναι υψηλός**. Η μέθοδος αυτή είναι memoryless, με την έννοια ότι κάθε ανάθεση είναι ανεξάρτητη της προηγούμενης, επομένως δεν υπάρχει κάποιος σχεδιασμός που να εξασφαλίζει ότι αν τύχει να έχουμε την ίδια θεραπεία συνεχόμενα, θα διορθώνουμε για αυτό.
  - Όπως φάνηκε και από τη παραπάνω ανάλυση, για $N = 80$ ασθενείς η πιθανότητα να έχουμε τέλεια ισορροπία ήταν μόλις 8,89 % με τη πιθανότητα να έχουμε σημαντική απόκλιση από την αναλογία 1:1 να είναι υπαρκτή (όπως φάνηκε και στο simulation), γεγονός που

μπορεί να μειώσει τη στατιστική ισχύ της μελέτης. Ενώ, ταυτόχρονα δεν υπάρχει κάποιο όριο/κανόνας για την μέγιστη δυνατή ανισορροπία.

- **Σενάριο B (Block Randomization, block = 4):**
  - **Δεν υπάρχει κίνδυνος ανισορροπίας.** Η συγκεκριμένη μέθοδος χαρακτηρίζεται από `Perfect Memory`. Εξαναγκάζει ισορροπία κάθε $b = 4$ ασθενείς.
  - Πιο συγκεκριμένα, η μέγιστη προσωρινή ανισορροπία που μπορεί να υπάρξει είναι $\frac{b}{2}$. Έτσι, αν $b = 4$, η διαφορά των ομάδων $|N_A - N_B|$ δε μπορεί να υπερβεί ποτέ τους 2 ασθενείς. Άρα στο τέλος της μελέτης ($N = 80$), η ισορροπία θα είναι ακριβώς 40-40.

Προβλεψιμότητα και Selection Bias

- **Σενάριο A:**
  - **Δεν υπάρχει προβλεψιμότητα.** Όπως ήδη αναφέραμε η μέθοδος αυτή δεν έχει μνήμη, δηλαδή κάθε ανάθεση είναι ανεξάρτητη, όπως η ρίψη ενός νομίσματος. Άρα, είναι αδύνατον για τον ερευνητή να προβλέψει την επόμενη θεραπεία ανεξαρτήτως από το τι έχουν πάρει οι προηγούμενοι ασθενείς.
  - Συνεπώς, ο κίνδυνος για **Selection Bias** θεωρείται αν όχι ανύπαρκτος, τουλάχιστον ελάχιστος.
- **Σενάριο B:**
  - Εδώ υπάρχει **υψηλή προβλεψιμότητα** (στο τέλος των blocks).Εφόσον, το μέγεθος του block είναι σταθερό (και μικρό), η ακολουθία μπορεί να γίνει πάρα πολύ εύκολα προβλέψιμη για τον ερευνητή. Για παράδειγμα, αν σε ένα block είχαν δοθεί δύο A και ένα B και ο ερευνητής/κλινικός είχε καταλάβει ότι έχουμε σταθερό αριθμό block 4, τότε γνωρίζει με βεβαιότητα ότι ο επόμενος ασθενής θα πάρει B.
  - Αυτό, δημιουργεί κίνδυνο για **Selection Bias**, ειδικά σε open label μελέτες, αφού με αυτό το τρόπο είναι πολύ εύκολο στο προσωπικό να επηρεάσει ποιος θα ενταχθεί και πότε στη μελέτη αν γνωρίζει τι θεραπεία θα λάβουν.

3.5 Επιλογή Σχεδιασμού

- **Open-Label μελέτη:** Σε αυτή τη περίπτωση, ο ερευνητής γνωρίζει τι θεραπεία πήραν οι προηγούμενοι ασθενείς, και άρα αν χρησιμοποιήσουμε σταθερά blocks όπως στο Σενάριο Β η ακολουθία γίνεται προβλέψιμη και μπορεί όπως είπαμε να οδηγήσει εύκολα σε Selection Bias. Για αυτό το λόγο, θεωρούμε ότι η επιλογή του **Σεναρίου Α** με Simple Randomization σαν memoryless μέθοδος που είναι, είναι η καλύτερη επιλογή υπό τις παρούσες συνθήκες.

- **Double-Blind μελέτη:** Στη περίπτωση μιας τέτοιας μελέτης ο ερευνητής/κλινικός δε μπορεί να γνωρίζει τι θεραπεία έχουν πάρει οι προηγούμενοι ερευνητές, η μελέτη είναι όπως λέμε "τυφλή". Έτσι, ακόμα και αν χρησιμοποιήσουμε σταθερά blocks, δεν υπάρχει πιθανότητα ο ερευνητής να μπορέσει να προβλέψει τι ακολουθεί. Ταυτόχρονα, αφού δεν υπάρχει το πρόβλημα της πρόβλεψης και του Selection Bias η συγκεκριμένη μέθοδος όπως αναφέραμε και νωρίτερα έχει πολλαπλά οφέλη σε σχέση με τη Simple Randomization, αφού εγγυάται απόλυτη ισορροπία. Για αυτούς τους λόγους θα επιλέγαμε το **Σενάριο Β**.

3.6 Έλεγχος Συνέπειας

Σε περίπτωση που κατά λάθος γράφαμε blocks μεγέθους 3 αντί για 4, το πρώτο χαρακτηριστικό που θα πρόδιδε το λάθος μας θα ήταν το γεγονός ότι θα βλέπαμε πως δε θα υπήρχε ισορροπία μέσα στα blocks. Όπως γνωρίζουμε το μέγεθος του block πρέπει να είναι υποχρεωτικά πολλαπλάσιο του αριθμού των θεραπειών (οπότε σε εμάς πολλαπλάσιο του 2). Ο αριθμός 3 είναι περιττός, δε γίνεται να μοιράσουμε 3 ασθενείς σε 2 ομάδες ομοιόμορφα. Στη λίστα πιθανότατα θα βλέπαμε υψηλή συστηματική ανισορροπία. Ωστόσο, επειδή η συνάρτηση blockrand είναι φτιαγμένη για να προστατεύει από τέτοια λάθη αν εμείς κατα λάθος βάζαμε block size = 3 η `R` θα το μετάφραζε σαν 3×2 με αποτέλεσμα να βλέπαμε στο output στη στήλη block.size τον αριθμό 6 όπως φαίνεται στο παρακάτω Πίνακα 8 του παρακάτω κώδικα:

Listing 10: wrong block size = 3

```
wrong_size_test <- blockrand(
  n = N,
  num.levels = 2,
  levels = c("A", "B"),
  block.sizes = 3
)

#check block.size number
head(wrong_size_test, 10)
```

Table 8: Έλεγχος Συνέπειας: Αποτέλεσμα Λανθασμένης Παραμέτρου (Block Size 3)

id	block.id	block.size	treatment
1	1	6	A
2	1	6	B
3	1	6	A
4	1	6	B
5	1	6	B
6	1	6	A
7	2	6	A
8	2	6	A
9	2	6	B
10	2	6	B

4 Interim Analysis, O'Brien-Fleming & Pocock

Έστω μία μελέτη επιβίωσης (Survival), ο σχεδιασμός της οποίας προβλέπει συνολικά 180 events (θανάτους/συμβάντα) για τη τελική ανάλυση. Θα εφαρμόσουμε ενδιάμεσες αναλύσεις σε δύο διαφορετικά σενάρια:

- **Σενάριο A:** O'Brien-Fleming
- **Σενάριο B:** Pocock

με βάση τις παρακάτω παραμέτρους:

- $\alpha = 0.05$ σε two-sided οπότε εισάγεται ως $\alpha = 0.025$ one-sided στη library gsDesign που χρησιμοποιήσαμε.
- power= 80%
- 3 looks σε information fractions: 30%, 60%, 100% των events

Ο κώδικας που χρησιμοποιήθηκε για την επίλυση της άσκησης δίνεται παρακάτω:

4.0.1 Κώδικας

Listing 11: Interim Analysis

```
library(gsDesign)
#Scenario A O-F
scenA= gsDesign(
  k=3,
  test.type = 2, # two sided symmetric
  alpha = 0.025,
  beta = 0.2,
  timing = c(0.3,0.6,1),
  sfu = "OF")
scenA
gsBoundSummary(scenA)
#Scenario B Pocock
scenB=gsDesign(
  k=3,
  test.type = 2,
  alpha = 0.025,
  beta = 0.2,
  timing = c(0.3,0.6,1),
  sfu = "Pocock")
scenB
gsBoundSummary(scenB)
```

4.1 Boundaries

Σε αυτό το σημείο θα υπολογίσουμε τα όρια (Z-score και $p - value$ scale) για κάθε look και στα δύο σενάρια. Οι παρακάτω πίνακες (Πίνακας 9 & Πίνακας 10) δίνιυν τα τα όρια απόρριψης της H_0 με βάση τα outputs του παραπάνω κώδικα:

Table 9: O'Brien-Fleming Boundaries (Σενάριο A)

Look	Information Fraction (%)	Z-Score Critical	p-value (1-sided)	p-value (2-sided nominal)
1	30%	3.638	0.0001	0.0002
2	60%	2.573	0.0050	0.0100
3	100%	1.993	0.0231	0.0462

Table 10: Pocock Boundaries (Σενάριο B)

Look	Information Fraction	Z-Score Critical	p-value (1-sided)	p-value (2-sided nominal)
1	30%	2.299	0.0107	0.0214
2	60%	2.299	0.0107	0.0214
3	100%	2.299	0.0107	0.0214

4.2 Σύγκριση Thresholds

Συγκρίνοντας τις δύο μεθόδους παρατηρούμε τα εξής:

- **O'Brien Fleming:** Τα όρια είναι πολύ υψηλά στην αρχή και σταδιακά μειώνονται, καθιστώντας έτσι, εξαιρετικά δύσκολη την πρόωρη διακοπή της μελέτης, εκτός και αν υπάρχει κάποιο εξαιρετικά ακραίο αποτέλεσμα/όφελος. Αυτό δείχνει το πόσο συντηρητική είναι στην αρχή η μελέτη. Ωστόσο, η μέθοδος έχει και ένα σημαντικό πλεονέκτημα, αφού όπως φαίνεται στο τέλος της μελέτης, το Z-score είναι πολύ κοντά στο κλασσικό όριο του 1,96 ($p - value \approx 0.05$), διατηρώντας έτσι τη στατιστική ισχύ στην τελική ανάλυση.

- **Pocock:** Τα όρια εδώ παραμένουν σταθερά ($Z = 2,299$) σε όλη τη διάρκεια της μελέτης. Αυτό καθιστά τη πρόωρη διακοπή πιο εύκολη (αφού το κριτικό όριο είναι χαμηλό) με κόστος ωστόσο ότι στη τελική ανάλυση απαιτείται πολύ πιο αυστηρό επίπεδο στατιστικής σημαντικότητας κάνοντας έτσι πιο δύσκολο η μελέτη να καταλήξει σε επιτυχία. Ενώ ταυτόχρονα προκαλεί και μεγάλη αύξηση του δείγματος (Sampe size Inflation $\approx 20\%$).

4.3 Scenario Testing

Στη 2^{η} ενδιάμεση ανάλυση (60% των events) παρατηρήθηκε $Z_{obs} = 2.30$. Η απόφαση για Stop for Efficacy ή Continue ανάλογα με το επιλεγμένο Σενάριο δίνεται παρακάτω:

Σενάριο A (OF) :

Το όριο απόφασης όπως φαίνεται στο Πίνακα 9 είναι $Z_{crit} = 2.57$. Άρα, αφού $Z_{obs} < Z_{crit}$, απόφαση είναι για **Συνέχιση (Continue)** της μελέτης.

Σενάριο B (Pocock) :

Σε αυτή τη περίπτωση όπως βλέπουμε στο Πίνακα 10 η 2^{η} ενδιάμεση ανάλυση έχει $Z_{obs} = 2.299$ (όπως άλλωστε και κάθε στάδιο αφού το Z είναι σταθερό). Άρα, $Z_{obs} < Z_{crit}$ σταματάμε για Efficacy. Σταματάει η μελέτη δηλαδή σε αυτό το σημείο ως επιτυχής (αποτελεσματικότητα).

4.4 Επιλογή (Selection)

Εφόσον ο χορηγός ανησυχεί αρκετά για το Type I error, θα πρότεινα τη μέθοδο του O'Brien Fleming. Η συγκεκριμένη μέθοδος ξοδεύει ελάχιστο α στην αρχή της μελέτη, προστατεύοντας με αυτό το τρόπο από μία πρόωρη διακοπή της μελέτης που μπορεί να οφείλεται σε τυχαίες διακυμάνσεις λόγω των αρχικών ασταθών δεδομένων (αφού ο αριθμός των events στην αρχή είναι πολύ μικρός), μειώνοντας με αυτό το τρόπο το κίνδυνο ενός ψευδώς θετικού αποτελέσματος. Ενώ ταυτόχρονα διατηρεί το τελικό όριο πολύ κοντά στο κλασσικό όριο του 1.96 .

4.5 Έλεγχος Συνέπειας

Αν αλλάζαμε το α σε one-sided 0.025 τα όρια Z πρακτικά θα παρέμεναν ίδια. Στη κανονική κατανομή, σαν συμμετρική κατανομή που είναι, ένας two-sided έλεγχος με $\alpha = 0.05$ κατανέμει το σφάλμα ομοιόμορφα στις δύο ουρές (0.025 σε κάθε ουρά), έτσι το άνω όριο απόρριψης καθορίζεται από το άνω ποσοστημόριο $Z_{1-\frac{\alpha}{2}} = Z_{1-0.025} = Z_{0.975} \approx 1.96$. Αντίστοιχα, σε έναν one-sided έλεγχο με $\alpha = 0.025$, εφόσον ελέγχουμε σε μόνο μία απ'τις δύο ουρές, έχουμε κριτικό όριο $Z_{1-\alpha} = Z_{1-0.025} = Z_{0.975} \approx 1.96$. Οπότε, και στις δύο περιπτώσεις καταλήγουμε στο ίδιο ακριβώς κριτικό όριο Z. Άρα **όχι**, τα όρια δεν θα άλλαζαν.

5 ΜΕΡΟΣ Β: Θεωρία

5.1 Phase I Designs

Ερώτημα: Ποια είναι τα βασικά μειονεκτήματα του αλγορίθμου "3+3" όσον αφορά την υποεκτίμηση της MTD;

Ο αλγόριθμος "3+3" είναι σχεδιασμένος με βασικό στόχο την ασφάλεια. Αυτό έχει σαν αποτέλεσμα πολλές φορές να είναι υπερβολικά συντηρητικός. Είναι ένας memoryless αλγόριθμος που στηρίζεται για τις αποφάσεις του αποκλειστικά στη τρέχουσα κοορτή των 3 ή 6 ατόμων της τρέχουσας δόσης, μη λαμβάνοντας υπόψη τις πληροφορίες που μπορεί να υπήρχαν από προηγούμενες ενδεχόμενες δόσεις. Με αυτό το τρόπο έχει τη τάση να σταματά νωρίτερα, συχνά σε χαμηλότερα επίπεδα δόσης από τη πραγματική MTD. Το παραπάνω φάνηκε και στην Άσκηση 1 στο Σενάριο Β όπου ο αλγόριθμος αποτύγχανε να φτάσει τη δόση στόχο (Dose 3) και σταμάταγε νωρίτερα στις δόσεις 1 ή 2.

Ερώτημα: Ποια προβλήματα προσπαθούν να επιλύσουν τα Model-Based Designs (π.χ. CRM) ; Είδατε κάποια ένδειξη αυτών των προβλημάτων στους αριθμητικούς υπολογισμούς της Άσκησης 1;

Τα Model-Based Designs (όπως το CRM) στοχεύουν στη σταδιακή αύξηση της δόσης και στην έκθεση όσο το δυνατόν λιγότερων ασθενών σε μη ασφαλείς ή μη αποτελεσματικές δόσεις. Αυτό προσπαθούν να το επιτύχουν εκτιμώντας ολόκληρη τη καμπύλη dose-toxicity χρησιμοποιώντας όλα τα διαθέσιμα δεδομένα.

Στην Άσκηση 1, στο Σενάριο Β όπως ήδη αναφέραμε, ήταν αρκετά εμφανές το πρόβλημα της υποεκτίμησης, όπου η πραγματική target dose ($p \approx 0.30$) ήταν η Dose 3 ($p = 0.28$). Όπως υπολογίσαμε ο αλγόριθμος επέλεξε σωστά την Dose 3 σαν MTD μόλις στο 21.4% των περιπτώσεων.

5.2 Phase II Designs

Ερώτημα: Γιατί είναι επισφαλές να αντιμετωπίζουμε τη Phase II απλώς ως μια "μικρή Phase III";

Ο βασικότερος λόγος είναι το γεγονός ότι οι δύο αυτές μελέτες στοχεύον σε διαφορετικά πράγματα. Οι μελέτες Phase II είναι συνήθως μη συγκριτικές μελέτες, με μικρό δείγμα στις οποίες μας ενδιαφέρει η αποτελεσματικότητα με την έννοια της δραστικότητας (activity) του φαρμάκου και όχι το effectiveness που μας ενδιαφέρει στις Phase III (στις οποίες απαιτείται και μεγάλο δείγμα). Αν τις αντιμετωπίσουμε σαν μικρές Phase III, και ειδικά χωρίς τη κατάλληλη τυχαιοποίηση και ισχύ, κινδυνεύουμε να οδηγηθούμε σε λανθασμένα συμπεράσματα και άσκοπη σπατάλη πόρων ή και έκθεσης ασθενών σε αναποτελεσματικές θεραπείες σε επόμενα στάδια.

Ερώτημα: Ποιος είναι ο ρόλος των p_0 και p_1;

Το p_0 αντιπροσωπεύει το μέγιστο "μη αποδεκτό" ποσοστό ανταπόκρισης (συνήθως η ιστορική αποτελεσματικότητα), κάτω από το οποίο το φάρμακο θεωρείται αποτυχία. Το p_1 είναι το ελάχιστο "επιθυμητό" ποσοστό που θα δικαιολογούσε περαιτέρω έρευνα. Ο σχεδιασμός (Simon/Single stage) προσπαθεί να διακρίνει αυτές τις δύο τιμές.

Ερώτημα: Ποιο είναι το ρίσκο αν επιλέξουμε ένα υπερβολικά αισιόδοξο p_1 όσον αφορά το Sample Size και το Power;

Αν επιλέξουμε ένα υπερβολικά αισιόδοξο p_1 (δηλαδή έχουμε μεγάλο effect size), το απαιτούμενο μέγεθος δείγματος N θα βγει μικρό. Έτσι, αν η πραγματική δόση του φαρμάκου είναι μέτρια (και ενδεχομένως χρήσιμη), η μελέτη δε θα έχει την απαιτούμενη ισχύ για να την εντοπίσει, κινδυνεύοντας με αυτό το τρόπο να απορρίψουμε μία χρήσιμη θεραπεία (Type II Error).

5.3 Randomization & Bias

Ερώτημα: Γιατί η απλή "ρίψη νομίσματος" (Simple Randomization) μπορεί να είναι προβληματική σε μικρές κλινικές δοκιμές;

Η Απλή Τυχαιοποίηση εγγυάται ισορροπία ασυμπτωτικά σε μεγάλα N με βάση τον Ισχυρό Νόμο των Μεγάλων Αριθμών. Έτσι, αν έχουμε μικρό δείγμα υπάρχει υψηλός κίνδυνος για σοβαρή ανισορροπία. Μάλιστα όπως είδαμε στην Άσκηση 3 θεωρητικά υπάρχει μόλις $\approx 8.89\%$ πιθανότητα να έχουμε τέλεια ισορροπία ενώ από την προσομοίωση είδαμε ότι το δ.ε. ήταν από $0,40$ μέχρι 0,61 επιβεβαιώνοντας ότι η αναλογία ήταν μακρυά απ'το 1:1.

Ερώτημα: Πώς τα block designs προσπαθούν να λύσουν το πρόβλημα της χρονικής ανισορροπίας (chronological bias) ;

Βασικό πλεονέκτημα της τυχαιοποίησης σε blocks είναι ότι εξασφαλίζει η αναλογία των θεραπειών να παραμένει 1:1 σε τακτά χρονικά διαστήματα (στο τέλος κάθε block). Έτσι, αν κατά τη διάρκεια μιας μελέτης τύχει να αλλάξουν οι συνθήκες της νοσηλείας, αποτρέπεται το ενδεχόμενο η μία ομάδα να έχει περισσότερους ασθενείς απ'την άλλη, αφού οποιαδήποτε αλλαγή θα επηρεάσει ισότιμα και τις δύο ομάδες.

5.4 Interim Analysis

Ερώτημα: Εξηγήστε διαισθητικά γιατί οι πολλαπλοί έλεγχοι (multiple looks) "φουσκώνουν" το σφάλμα τύπου I. Πως αντιμετωπίζεται αυτό στην Άσκηση 4 ;

Κάθε φορά που κάνουμε έναν στατιστικό έλεγχο υπάρχει μια μικρή πιθανότητα (συνήθως 5%) να βρούμε κάποια διαφορά από τύχη. Αν χρειαστεί να κάνουμε πάνω από έναν τέτοιους ελέγχους, τότε κάθε μία από αυτές τις ευκαιρίες που έχουμε να κάνουμε αυτό το τυχαίο λάθος αθροίζονται. Έτσι, το Type I Error αυξάνεται δραματικά.

Ερώτημα: Ποιος είναι ο ρόλος της ανεξαρτησίας της επιτροπής DSMB ;

Η DSMB είναι η μόνη που έχει πρόσβαση σε unblinded δεδομένα κατά τη διάρκεια των ενδιάμεσων αναλύσεων.Για αυτό, πρέπει να είναι ανεξάρτητη τόσο από τους ερευνητές όσο και από το χορηγό έτσι ώστε να αποφεύγεται το conflict of interests και να μπορούν να προστατεύουν τους ασθενείς διακόπτοντας αν χρειαστεί εξαιτίας κάποιας ενδεχόμενης επικίνδυνης ή αναποτελεσματικής θεραπείας. Διαφορετικά, οι ερευνητές μπορεί να μπούνε στο δίλημμα να συνεχίσουν κάποια μελέτη που δε θα έπρεπε για επιστημονική δόξα ή οι χορηγοί για οικονομικούς λόγους.

Ερώτημα: Ποιο είναι το μεγαλύτερο πρακτικό ρίσκο αν "ξέρουν όλοι" τα interim αποτελέσματα ;

Αν τα ενδιάμεσα αποτελέσματα είναι γνωστά σε όλους τότε εισάγεται μεροληψία. Οι κλινικοί για παράδειγμα μπορεί να αρνηθούν να τυχαιοποιήσουν ασθενείς σε μία ομάδα που μπορεί να φαίνεται ότι πηγαίνει λιγότερο καλά, οδηγώντας με αυτό το τρόπο σε πιθανό Selection Bias.

5.5 ITT vs Per Protocol

Ερώτημα: Γιατί η ανάλυση Intention-to-Treat (ITT) θεωρείται πιο "συντηρητική" και πιο κοντά στην πραγματική κλινική πρακτική ;

Σε μία ITT ανάλυση συμπεριλαμβάνουμε όλους τους ασθενείς στην ομάδα που αρχικά τυχαιοποιήθηκαν ανεξάρτητα από το αν συμμορφώθηκαν με τη θεραπεία ή όχι. Θεωρείται οπότε συντηρητική, επειδή περιλαμβάνει και όλους αυτούς τους ασθενείς οι οποίοι είτε δεν έλαβαν τη θεραπεία είτε απλά δεν ακολούθησαν το πρωτόκολλο. Αυτοί οι ασθενείς (non-compliers), όταν συμπεριλαμβάνονται σε μελέτες συνήθως τείνουν το αποτέλεσμα της μελέτης προς τη μηδενική υπόθεση, μειώνοντας ουσιαστικά την παρατηρούμενη διαφορά. Έτσι, επειδή είναι πιο δύσκολη η απόδειξη της υπεροχής, αν βρούμε διαφορά τότε αυτή είναι πολύ αξιόπιστη. Θεωρείται πιο κοντά στην πραγματική κλινική πρακτική, επειδή αντικατοπτρίζει τα αποτελέσματα στην πραγματική ζωή (effectiveness), όπου συχνά οι ασθενείς δεν συμμορφώνονται ακριβώς με το πρωτόκολλο ξεχνώντας ή διακόπτοντας κάποια θεραπεία.

Ερώτημα: Σε ποιες περιπτώσεις η ανάλυση Per-Protocol μπορεί να οδηγήσει σε μεροληπτικά συμπεράσματα (bias) ;

Η ανάλυση Per Protocol εξαιρεί όλους τους non-compliers ασθενείς. Όμως, πολλές φορές η μη συμμόρφωση σχετίζεται με την πρόγνωση (π.χ. ασθενείς με κάποια πολύ βαριά (ανίατη) ασθένεια μπορεί διακόπτουν συχνότερα λόγω παρενεργειών θεωρώντας ότι δεν έχει νόημα η θεραπεία). Εξαιρώντας οπότε αυτούς τους ασθενείς, και κρατώντας οπότε τους πιο "δυνατούς", σπάμε την τυχαιοποίηση και εισάγουμε σοβαρό Selection Bias, υπερεκτιμώντας με αυτό το τρόπο το effectiveness.

6 Συνολικός Κώδικας

Ο συνολικός Κώδικας που χρειάστηκε για ολοκλήρωση όλης της εργασία δίνεται παρακάτω:

Listing 12: Overall Code

```
setwd("C:/Users/xrist/OneDrive␣-␣National␣and␣
   Kapodistrian␣University␣of␣Athens/Clinical␣Trials/
   Assignment")
set.seed(123)
OC_3plus3= function(p, doses=NULL){
  if (is.null(doses)) {
    doses= paste("Dose",seq_along(p))
  }
  Pi= dbinom(0,size = 3, prob = p)+dbinom(1,size=3,prob=p
     )*dbinom(0,size = 3, prob = p)
  Qi=cumprod(Pi)
  OC=1-Qi
  data.frame(
    dose= doses,
    p=p,
    Pi=Pi,
    Qi= Qi,
    OC= OC
  )
}
res_ScenA=OC_3plus3(c(0.08,0.18,0.30,0.45))
res_ScenB=OC_3plus3(c(0.12,0.22,0.28,0.40))
res_ScenA
res_ScenB

#MTD Calc
```

```
#we want to calculate the difference OC[i]-OC[i-1]
#aka the probability of stopping the study exactly
# at dose i

#Scenario A
stop_probA= diff(c(0,res_ScenA$OC))
stop_probA
MTD_probs_A= c(
  None= stop_probA[1], #stop at dose 1 -> no MTD
  Dose1=stop_probA[2], #stop at dose 2 -> MTD Dose= 1
  Dose2=stop_probA[3], # stop at Dose 3 -> MTD Dose= 2
  Dose3= stop_probA[4], # stop at Dose 4 -> MTD Dose= 3
  Dose4=1- res_ScenA$OC[4]#No stopping at all->MTD=Dose 4
)
MTD_probs_A

# Scenario B
stop_probs_B = diff(c(0, res_ScenB$OC))
MTD_probs_B = c(
  None  = stop_probs_B[1],
  Dose1 = stop_probs_B[2],
  Dose2 = stop_probs_B[3],
  Dose3 = stop_probs_B[4],
  Dose4 = 1 - res_ScenB$OC[4]
)

#results
round(MTD_probs_A, 3)
round(MTD_probs_B, 3)

##### Askisi 2 ####
library(clinfun)
#Scenario A
single_stage= function(p0,p1,alpha,power) {
  n=1
  while(TRUE) {
    #find the smallest k : P(X>k|p0)<=alpha
    kvec=0:n
    ptail0= pbinom(kvec,size = n, prob = p0, lower.tail =
        F)
    idx= which(ptail0<=alpha)[1]

    if (!is.na(idx)) {
```

```
      k_crit=kvec[idx] #if X>k_crit we reject H0
      #we calculate the power P(X>k_crit|p1)
      ptail1= pbinom(k_crit,size = n,prob = p1,lower.tail
          = F)

      if (ptail1>=power) {
        return(c(n=n,k=k_crit,alpha_exact=ptail0[idx],
           power_exact=ptail1))
      }
    }
    n=n+1
  }
}

res_single_A <-single_stage(0.15, 0.40, 0.10, 0.80)
round(res_single_A,3)
res_single_B <- single_stage(0.20, 0.40, 0.05, 0.90)
round(res_single_B,3)

results_table <- rbind(res_single_A, res_single_B)


### Two Stage Design ###
library(clinfun)
#Scenario A
simon_A= ph2simon(pu=0.15,pa=0.40,ep1 = 0.10,ep2 = 0.20,
   nmax = 100)
#Scenario B
simon_B=ph2simon(pu=0.20,pa=0.40,ep1 = 0.05,ep2 = 0.10,
   nmax = 100)

#Results
simon_A
simon_B



##find power if p=0.3
p_true=0.3
# Scenario A
# Parameters: n1=7, r1=1, Total_N=18, Total_r=4
# Rule: Stop if Stage 1 responses (x1) <= 1.
#Continue if x1 > 1.
```

```
# Logic: We sum the probabilities only for cases where
#the trial continues (x1 from 2 to 7).
n1=7
r1=1
N=18
r=4
n2=N-n1
x1_val= (r1+1):n1
power_A=sum(dbinom(x1_val,n1,p_true)
 # probability of getting enough responses in stage 2
 # to reach total r>4
            *pbinom(r-x1_val,n2,p_true,lower.tail =F ))
            #we need x2< (4-x1) from the remaining
            # 18-7 patients
round(power_A,3)

#Scenario B
# Parameters: n1=24, r1=5, Total_N=45, Total_r=13
# We stop if Stage 1 responses (x1) <= 5.Continue if x1>5
# Logic: The loop runs for x1 = 6 to 24
n1 = 24
r1 = 5
N  = 45
r  = 13
n2 = N - n1
x1_val= (r1+1):n1
power_B <- sum(
  # Probability of observing x1 responses in Stage 1
  #(x1 must be > 5 to continue)
  dbinom(x1_val, n1,p_true) * # Probability of success
  #in Stage 2 given x1
    # We need total responses > 13, so x2 > (13 - x1)
    pbinom(r-x1_val, n2, p_true, lower.tail=F)
)
round(power_B,3)


### Askisi 3 ####
set.seed(123) #for reproducibility
N=80
prob_exact=dbinom(x=N/2,size = N,p=0.5)
round(prob_exact,4)
```

```
# Simulation
#Simulation Parameters
N=80
K=1000

results= data.frame(
  replication = 1:K,
  NumberA= NA_integer_
)

#loop
for (i in 1:K) {
  u= runif(N)
  #We directly calculate the number in Arm A.
  results$NumberA[i]=sum(u<0.5)
}
ci_95= quantile(results$NumberA/N, probs = c(0.025,0.975)
   )
round(ci_95,4)

#Scenario B Block Randomization
#Block size=4
library(blockrand)
block_rand=blockrand(
  n=N,
  num.levels = 2,
  levels = c("A","B"),
  block.sizes = 2 # num.levels*block.sizes=4
)
first_20 =head(block_rand,20)
# Check Balance
table(block_rand$treatment)

wrong_size_test <- blockrand(
  n = N,
  num.levels = 2,
  levels = c("A", "B"),
  block.sizes = 3
)

#check block.size number
head(wrong_size_test, 10)
```

```
#### Askisi 4 ####
library(gsDesign)
#Scenario A O-F
scenA= gsDesign(
  k=3,
  test.type = 2, # two sided symmetric
  alpha = 0.025,
  beta = 0.2,
  timing = c(0.3,0.6,1),
  sfu = "OF"
)
scenA
gsBoundSummary(scenA)

#Scenario B Pocock
scenB=gsDesign(
  k=3,
  test.type = 2,
  alpha = 0.025,
  beta = 0.2,
  timing = c(0.3,0.6,1),
  sfu = "Pocock"
)
scenB
gsBoundSummary(scenB)
```